

0111011101010330
0101011101010330
0101011101010111
0101011601010111
0101001011010111

Consumo Digital en Adolescentes

Segmentación y caracterización de perfiles mediante Aprendizaje No Supervisado



Materia: Aprendizaje Automático

Integrantes:

Gisela Martinez

Noelia Cualina

Leonardo Carabajal

Javier Carabajal

Docente: Fabiana Escobar, Ana Maria Nardin, Luján Cazenabe

0111011101010330
0101011101010330
0101011101010111
0101011601010111
0101001011010111

Descripción del contexto y del problema

Contexto

El uso de dispositivos electrónicos, redes sociales, videojuegos y servicios de televisión o streaming forma parte de la vida cotidiana de los adolescentes. Sin embargo, el comportamiento digital no necesariamente es homogéneo: dos adolescentes pueden presentar una cantidad similar de horas de exposición a pantallas y, aun así, distribuir ese tiempo de manera muy diferente entre redes sociales, videojuegos, juegos en dispositivos móviles, contenido audiovisual u otras actividades.

El sueño durante la adolescencia es especialmente relevante por su relación con el bienestar, el funcionamiento durante el día y el desempeño escolar.

A partir de la revisión del dataset se propone un enfoque orientado de aprendizaje no supervisado, donde el objetivo central será descubrir estructuras o perfiles naturales dentro de la población según sus patrones de comportamiento digital.

Consideramos que el dataset seleccionado es adecuado porque contiene información de adolescentes argentinos sobre variables demográficas, uso de distintos tipos de pantallas y dispositivos, uso próximo al horario de descanso, hábitos de sueño, somnolencia diurna, rendimiento académico entre otras variables relevantes. Esta combinación permite abordar el problema desde una perspectiva de segmentación y caracterización de grupos.

Los datos fueron recolectados en 1.257 adolescentes de entre 12 y 18 años pertenecientes a 52 escuelas de zonas urbanas y suburbanas de Argentina.



Problema

Un análisis del tiempo de pantalla puede ocultar patrones relevantes dentro de la población, es decir si todos los adolescentes son tratados como un único grupo, se pierde información sobre qué actividades predominan, qué dispositivos se utilizan con mayor frecuencia, en qué etapas etarias o escolares aparecen determinados comportamientos y cómo se distribuyen posteriormente variables relacionadas con el sueño o la somnolencia.

La pregunta que proponemos abordar mediante Machine Learning es:

¿Es posible identificar perfiles diferenciados de adolescentes según sus patrones de uso de pantallas mediante técnicas de aprendizaje automático no supervisado y caracterizar dichos perfiles a partir de sus hábitos y características?

Propósito del análisis

El propósito del trabajo es identificar estructuras y perfiles naturales dentro de la población adolescente a partir de sus características demográficas y patrones de uso de pantallas, utilizando **técnicas de aprendizaje automático no supervisado**.



Los grupos se formarán exclusivamente a partir de variables seleccionadas para el proceso de segmentación. Posteriormente, se analizarán en comparación con otras, para caracterizar y comprender mejor las particularidades de cada segmento. Este análisis no busca establecer relaciones causales entre las variables, sino **identificar perfiles, explorar asociaciones y generar conocimiento** que pueda servir como base para investigaciones posteriores o para el diseño de estrategias diferenciadas de prevención, educación, concientización y comunicación.

0111011101010330
0101011101010330
0101011101010111
0101011601010111
0101001011010111

Descripción del dataset

Fuente:

El dataset utilizado corresponde al estudio: **Screen use, sleep duration, daytime somnolence, and academic failure in school-aged adolescents**

Los autores son **Daniel Pérez-Chada, Sergio Arias Bioch, Daniel Schönfeld, David Gozal y Santiago Perez-Lloret**, entre otros integrantes del *Sleep in Adolescents Collaborative study group*. El artículo fue publicado en *PLOS ONE* en 2023.

Los datos fueron recolectados entre **mayo y noviembre de 2019** y corresponden a adolescentes de Argentina. El repositorio institucional de CONICET identifica el recurso como un **dataset de acceso abierto**.

Ref: [Screen use, sleep duration, daytime somnolence, and academic failure in school-aged adolescents](#)

Características del dataset

El estudio original contiene información de:

- **1.257 adolescentes**
- Edad: **12 a 18 años**
- **52 escuelas**
- Escuelas ubicadas en zonas urbanas y suburbanas de Argentina.
- Uso de videojuegos.
- Uso de redes sociales.
- TV y streaming.
- Uso de dispositivos electrónicos antes de dormir.
- Hábitos de sueño durante días de semana y fines de semana.
- Somnolencia diurna.
- Rendimiento académico en Lengua y Matemática.

Nuestro archivo

El **repositorio.xlsx** que estamos utilizando contiene:

- **4.115 filas × 125 columnas**

Nuestro Excel contiene registros y variables adicionales derivadas/procesadas, por lo que en la etapa de preprocesamiento tendremos que identificar la **muestra válida para nuestro problema**.

Semántica de las variables

Variable	Significado
IP	Dirección IP asociada al registro. Identificador administrativo; no debería utilizarse como predictor.
Submission ID	Identificador único del registro o respuesta del cuestionario.
Submission Date	Fecha y hora en que se registró la respuesta.
Código	Código identificador asignado al participante/registro.
investigador	Código del investigador o responsable que registró la información.
Colegio	Código correspondiente al colegio al que pertenece el participante.
Ciudad	Código correspondiente a la ciudad/localidad del participante.
grado	Grado o año escolar del participante.
edad	Edad del adolescente, en años.
Fecha de nacimiento	Fecha de nacimiento declarada por el participante.

0111011101010330
0101011101010330
0101011101010111
0101011601010111
0101001011010111

FECHA_NAC_RECOD	Fecha de nacimiento recodificada y normalizada.
Sexo	Sexo declarado del participante.
sexonum	Sexo del participante representado mediante una codificación numérica.
Altura en m	Altura del participante expresada en metros.
Peso en kg	Peso del participante expresado en kilogramos.
imc	Índice de Masa Corporal (IMC), calculado a partir del peso y la altura.
¿Cuál es el máximo nivel educativo alcanzado por tu padre, madre o tutor?	Nivel educativo máximo alcanzado por el padre, madre o tutor.
niveducpadresRECOD	Nivel educativo de los padres/tutores después de la recodificación de las respuestas originales.
¿Cuántos ambientes/habitaciones tiene el hogar donde vivís? (sin contar cocina y baño)	Cantidad de ambientes o habitaciones disponibles en el hogar, excluyendo cocina y baño.
¿Cuántos de estos ambientes/habitaciones se usan para dormir?	Cantidad de habitaciones del hogar utilizadas para dormir.
¿Cuántas personas además de vos viven en el hogar?	Cantidad de personas que viven en el hogar además del participante.
cantpersonasviviendaRECOD	Cantidad de personas del hogar después de aplicar una recodificación.

0111011101010330
0101011101010330
0101011101010111
0101011601010111
0101001011010111

¿Cuál es el máximo nivel educativo alcanzado por tu padre, madre o tutor?	Nivel educativo máximo alcanzado por el padre, madre o tutor.
niveducpadresRECOD	Nivel educativo de los padres/tutores después de la recodificación de las respuestas originales.
¿Cuántos ambientes/habitaciones tiene el hogar donde vivís? (sin contar cocina y baño)	Cantidad de ambientes o habitaciones disponibles en el hogar, excluyendo cocina y baño.
¿Cuántos de estos ambientes/habitaciones se usan para dormir?	Cantidad de habitaciones del hogar utilizadas para dormir.
¿Cuántas personas además de vos viven en el hogar?	Cantidad de personas que viven en el hogar además del participante.
cantpersonasviviendaRECOD	Cantidad de personas del hogar después de aplicar una recodificación.
¿Con qué frecuencia sentís tanto sueño que te cuesta prestar atención en la clase?	Frecuencia con la que el adolescente tiene sueño al punto de dificultar la atención en clase.
problemasatencionrecod	Misma información anterior, transformada a una codificación numérica.
¿Con qué frecuencia te quedás dormido/a o te da sueño mientras hacés la tarea?	Frecuencia con la que aparece sueño durante la realización de tareas escolares.

0111011101010330
0101011101010330
0101011101010111
0101011601010111
0101001011010111

¿Estás atento/a o alerta en clase?	Nivel/frecuencia con la que el participante se mantiene atento o alerta durante las clases.
¿Con qué frecuencia te sentís cansado y de mal humor durante el día?	Frecuencia de cansancio y mal humor durante el día.
¿Te cuesta levantarte de la cama a la mañana?	Dificultad para levantarse por la mañana.
¿Te volvéis a quedar dormido/a después de que te despertaron a la mañana?	Frecuencia con la que vuelve a dormirse después de ser despertado.
¿Necesitás que alguien te despierte por la mañana?	Necesidad de otra persona para despertarse.
¿Con qué frecuencia sentís que necesitás dormir más tiempo?	Frecuencia con la que siente necesidad de dormir más.
Resultado	Puntaje total obtenido en la escala de somnolencia/PDSS.
somno01pdss	Indicador binario de somnolencia diurna según PDSS; identifica si se alcanza el criterio establecido.
¿Cómo viajas al colegio la mayoría de las veces?	Medio de transporte utilizado habitualmente para ir al colegio.
¿Cuánto tiempo tardas desde que salís de tu casa hasta que llegas al colegio? (indica en horas, minutos)	Tiempo que tarda el participante en trasladarse desde su casa hasta el colegio.

0111011101010330
0101011101010330
0101011101010111
0101011601010111
0101001011010111

tpoviajemín	Tiempo de viaje al colegio transformado a una variable numérica. Conviene revisar esta variable porque algunas respuestas del archivo fueron ingresadas en formatos de hora/minuto diferentes.
¿Cuánto tiempo dormís la siesta los días de semana? (si no dormís siesta marca 00:00)	Duración de la siesta durante los días de semana.
dursiestasemanahr	Duración de la siesta durante los días de semana expresada numéricamente, en horas.
¿Cuánto tiempo dormís la siesta los fines de semana o feriados? (si no dormís siesta marca 000:00)	Duración de la siesta durante fines de semana o feriados.
¿Cuánto tiempo de pantalla (dispositivos electrónicos) utilizas antes de dormirte los días de semana?	Tiempo de exposición a dispositivos electrónicos antes de dormir durante los días de semana.
¿A qué hora cenas durante los días de semana?	Horario habitual de la cena durante los días de semana.
horacenaahr	Hora de la cena transformada a un formato numérico.
¿A qué hora te acostás los días de semana?	Hora habitual de acostarse durante los días de semana.
horasueñosemanahr-proc	Hora de acostarse durante la semana transformada/procesada numéricamente.
horasueñosemanahr	Hora de acostarse durante la semana en formato numérico ajustado para realizar cálculos de sueño.

0111011101010130
0101011101010130
0101011101010111
0101011601010111
0101001011010111

¿Cuánto tiempo en Minutos tardas en dormirte?	Tiempo de latencia del sueño: minutos que tarda en quedarse dormido después de acostarse.
¿A qué hora te levantás los días de semana?	Hora habitual de levantarse durante los días de semana.
horalevantarsesemanahr	Hora de levantarse durante la semana convertida a formato numérico.
tposueñoem	Duración total del sueño durante los días de semana, expresada en horas.
tposueñoemTRIMMED	Duración del sueño durante los días de semana después del tratamiento/recorte de valores extremos.
tposueñoemCAT	Duración del sueño durante los días de semana convertida en categorías.
¿A qué hora te acostás los fines de semana?	Hora habitual de acostarse durante los fines de semana.
horaacostarfsemanahr	Hora de acostarse durante el fin de semana convertida a formato numérico.
¿A qué hora te levantás los fines de semana?	Hora habitual de levantarse durante los fines de semana.
horalevantarsefsemanahr-proc	Hora de levantarse durante el fin de semana procesada numéricamente.
tpofsueñoem	Duración total del sueño durante los fines de semana, expresada en horas.
tposueñoemfsemanahr-TRIMMED	Duración del sueño durante los fines de semana después del tratamiento de valores extremos.

0111011101010330
0101011101010330
0101011101010111
0101011601010111
0101001011010111

tposueñoofsemCAT	Duración del sueño durante los fines de semana convertida en categorías.
difonsetsueño	Diferencia entre los horarios de inicio del sueño de días de semana y fines de semana.
tpopantallatotalhstrimmed	Tiempo total de pantalla después del tratamiento/recorte de valores extremos.
tpopantallatotalhscat	Tiempo total de exposición a pantallas convertido en categorías.
tpopantallatotalhscat2	Segunda versión categorizada del tiempo total de exposición a pantallas.
tpovideojuegosstrimmed	Tiempo de videojuegos después del tratamiento de valores extremos.
tpojuegotabletcelhstrimmed	Tiempo de juegos en tablet/celular después del tratamiento de valores extremos.
tporedeshstrimmed	Tiempo de uso de redes sociales después del tratamiento de valores extremos.
tpotvonlinehstrimeed	Tiempo de TV/contenido online después del tratamiento de valores extremos.
tpootrashstrimmed	Tiempo de otras actividades frente a pantallas después del tratamiento de valores extremos.
tpovideojuegosstrimmedCAT	Tiempo de videojuegos tratado y posteriormente convertido en categorías.

0111011101010330
0101011101010330
0101011101010111
0101011601010111
0101001011010111

tpojuegotabletcelhstrimmedCAT	Tiempo de juegos en tablet/celular tratado y convertido en categorías.
tporedeshstrimmedCAT	Tiempo de redes sociales tratado y convertido en categorías.
tpotvonlinehstrimeedCAT	Tiempo de TV/contenido online tratado y convertido en categorías.
tpootrashstrimmedCAT	Tiempo de otras actividades frente a pantallas tratado y convertido en categorías.
tpopantallatotalhstrimmed	Tiempo total de pantalla después del tratamiento/recorte de valores extremos.
tpopantallatotalhscat	Tiempo total de exposición a pantallas convertido en categorías.
tpopantallatotalhscat2	Segunda versión categorizada del tiempo total de exposición a pantallas.
tpovideojuegososhstrimmed	Tiempo de videojuegos después del tratamiento de valores extremos.
tpojuegotabletcelhstrimmed	Tiempo de juegos en tablet/celular después del tratamiento de valores extremos.
tporedeshstrimmed	Tiempo de uso de redes sociales después del tratamiento de valores extremos.
tpotvonlinehstrimeed	Tiempo de TV/contenido online después del tratamiento de valores extremos.
tpootrashstrimmed	Tiempo de otras actividades frente a pantallas después del tratamiento de valores extremos.
tpovideojuegososhstrimmedCAT	Tiempo de videojuegos tratado y posteriormente convertido en

0111011101010330
0101011101010330
0101011101010111
0101011601010111
0101001011010111

	categorías.
tpjuegotabletcelhstrimmedCAT	Tiempo de juegos en tablet/celular tratado y convertido en categorías.
tporedeshstrimmedCAT	Tiempo de redes sociales tratado y convertido en categorías.
tpotvonlinehstrimeedCAT	Tiempo de TV/contenido online tratado y convertido en categorías.
tpootrashstrimmedCAT	Tiempo de otras actividades frente a pantallas tratado y convertido en categorías.
tpovideojuegosPORC	Porcentaje del tiempo total de pantalla dedicado a videojuegos.
tpotabletPORC	Porcentaje del tiempo total de pantalla dedicado a juegos en tablet/teléfono celular.
tporedesPORC	Porcentaje del tiempo total de pantalla dedicado a redes sociales.
tpotvonlinePORC	Porcentaje del tiempo total de pantalla dedicado a TV, streaming o contenido online.
tpootrasPORC	Porcentaje del tiempo total de pantalla correspondiente a otras actividades.
tpovideojuegoshstrimmed01	Indicador binario de uso de videojuegos después del tratamiento de los datos.
tpjuegotabletcelhstrimmed01	Indicador binario de uso de juegos en tablet/celular.
tporedeshstrimmed01	Indicador binario de uso de redes sociales.

0111011101010330
0101011101010330
0101011101010111
0101011601010111
0101001011010111

tpotvonlinehstrimeed01	Indicador binario de uso de TV/contenido online.
cantdiascompus01	Indicador binario de uso de computadora/laptop durante la semana.
cantdiascelular01	Indicador binario de uso del teléfono celular durante la semana.
cantdiastablet01	Indicador binario de uso de tablet durante la semana.
cantdiasconsolajuegos01	Indicador binario de uso de consola de videojuegos durante la semana.
cantdiastv01	Indicador binario de uso de TV/Smart TV durante la semana.
WATCHTVbedtime7D01	Indicador binario de utilización de TV/contenido audiovisual durante el período previo al sueño, considerando los días registrados.
COMPUbedtime1D01	Indicador binario de uso de computadora cerca de la hora de dormir.
COMPUbedtime2D01	Segundo indicador binario relacionado con el uso de computadora cerca de la hora de dormir.
WAZ	Puntaje Z de peso para la edad (Weight-for-Age Z-score).
HAZ	Puntaje Z de talla/altura para la edad (Height-for-Age Z-score).
BAZ	Puntaje Z relacionado con el IMC/masa corporal según edad (BMI-for-Age Z-score).
BMIzscoreCAT	Categoría derivada del puntaje Z del IMC.
lengua	Calificación obtenida en la asignatura Lengua.
matematica	Calificación obtenida en la asignatura Matemática.

0111011101010330
0101011101010330
0101011101010111
0101011601010111
0101001011010111

prom	Promedio académico calculado a partir de las calificaciones disponibles.
aplazos	Indicador binario de presencia de aplazos/desaprobaciones.
datoscompletoDEMOG	Indicador de si los datos demográficos necesarios están completos.
datoscompletoSUENO	Indicador de si los datos relacionados con el sueño están completos.
datoscompletoPANTALLAS	Indicador de si los datos relacionados con el uso de pantallas están completos.
excSUENOpantallas	Indicador utilizado para identificar registros excluidos por criterios relacionados con sueño y/o pantallas.
excluidos	Indicador general de exclusión del registro según los criterios del procesamiento original.
missingnotas	Indicador de ausencia de calificaciones/notas académicas.
excluFINAL	Indicador final de inclusión/exclusión del registro para el análisis final.

0111011101010330
0101011101010330
0101011101010111
0101011601010111
0101001011010111

Propuesta de preprocesamiento y limpieza

Antes de realizar el entrenamiento de los modelos de Machine Learning será necesario preparar el conjunto de datos, identificando los registros y variables adecuados para el problema planteado. Para ello, se proponen las siguientes tareas:

1. Eliminación de variables no relevantes

Se identificarán y excluirán aquellas variables que no aporten información útil y que no estén relacionadas con el problema planteado. También se revisará la existencia de variables originales y sus correspondientes versiones recodificadas para evitar información redundante.

2. Tratamiento de datos faltantes

Se analizará la cantidad y distribución de valores faltantes en las variables seleccionadas. De acuerdo con la proporción y naturaleza de estos valores, se evaluará la eliminación de registros o variables y, cuando corresponda, la aplicación de técnicas de imputación.

3. Tratamiento de valores extremos e inconsistentes

Se analizarán principalmente las variables numéricas relacionadas con la duración del sueño y el tiempo de exposición a pantallas para detectar valores atípicos, imposibles o inconsistentes.

4. Conversión de variables categóricas

Las variables categóricas seleccionadas serán analizadas y transformadas a formatos adecuados para su utilización en los modelos de Machine Learning. Se revisarán también las variables que ya cuentan con versiones recodificadas o binarias para determinar cuál representación resulta más apropiada y evitar duplicaciones.

5. Selección de variables para el análisis

Se seleccionarán las variables que resulten pertinentes para responder al problema planteado. Se considerarán características demográficas y variables relacionadas con los hábitos de uso de pantallas.

6. Preparación de conjuntos experimentales

Se construirán distintas configuraciones de variables para comparar si los grupos se sostienen al considerar intensidad, composición del uso, frecuencia de dispositivos y contexto de uso antes de dormir.

0111011101010330
0101011101010330
0101011101010111
0101011601010111
0101001011010111

Flujo general de trabajo:

Las tareas de pre procesamiento y limpiezas descritas anteriormente formarán parte de un flujo de trabajo más amplio, que posteriormente incluirá la interpretación de los resultados obtenidos.

Flujo de Tareas:

